

Detección de Noticias Falsas mediante Modelos de Lenguaje Preentrenados

Ana Fuentes Rodríguez

Sistemas de Recuperación de
Información y de Recomendación

Curso 2024/25

Índice

1. Objetivos
2. Introducción
3. Marco Teórico
4. Metodología
5. Resultados
6. Conclusiones

Objetivos

- Desarrollar un sistema automático de detección de noticias falsas mediante procesamiento del lenguaje natural (**NLP**) y modelos de lenguaje profundo (**LLMs**)

Introducción

❖ Contexto actual

- Acceso inmediato y masivo a información
- Rápida propagación de ***fake news***
- Impacto en la opinión pública y en los procesos democráticos

❖ Problema

- Necesidad urgente de sistemas automáticos para detectar noticias falsas y proteger la integridad informativa

❖ Solución propuesta

- Uso de modelos de LLMs como herramienta eficaz frente a métodos tradicionales
- Clasificación de afirmaciones según veracidad

❖ Trabajo realizado

- Dos clasificadores entrenados sobre el dataset **LIAR**:
 1. Clasificador **multiclase** (6 clases)
 2. Clasificador **binario** ("verdadero" o "falso")
- Comparación de modelos mediante métricas de evaluación

Marco Teórico

❖ NLP (Procesamiento del Lenguaje Natural)

- Rama de la IA centrada en la comprensión e interpretación del lenguaje humano
- Tarea específica: Clasificación de texto según contenido semántico (ej. "verdadero" o "falso")

❖ Modelos de Lenguaje Profundo

- Ejemplo clave: **BERT** (Bidirectional Encoder Representations from Transformers)

1. Preentrenado con grandes datasets en inglés.
2. Modelo bidireccional: considera el contexto anterior y posterior de cada palabra
3. Resultados sobresalientes en clasificación, análisis de sentimiento y QA

❖ Aplicación al proyecto

- **BERT base uncased** y se ajustó con el dataset **LIAR**

- LIAR: +12.000 afirmaciones políticas etiquetadas en 6 niveles de veracidad

- Permite un análisis semántico profundo (más allá de palabras clave o patrones)

❖ Ventajas

- Capacidad para detectar lenguaje ambiguo, irónico o malintencionado
- Representación contextual y distribuida del significado

Metodología

Dataset utilizado

- LIAR dataset [1]
- Afirmaciones políticas; tema, autor, afiliación política.
- 6 etiquetas según el grado de veracidad
- Simplificación: 2 clases (Verdadero: 1, falso: 0)

Training set	Validation set	Test set
10256	1284	1267

[1] Q. Doan, “Liar-dataset”, 2022.

<https://www.kaggle.com/datasets/doanquanvietnamca/liar-dataset>

Metodología

Preprocesamiento

- Limpieza básica:
 1. Caracteres en minúscula
 2. Eliminación de caracteres especiales, URLs, etc
 3. Eliminación de ***stopwords***
- Dos esquemas de clasificación:

Multiclase	Binaria
Se mantienen las 6 categorías disponibles	Reagrupación de las clases en verdadero o falso

Metodología

Arquitectura del modelo

- ***BERT base-uncased***
- Fine tuning con ***Hugging Face Transformers***
- Capa de salida adaptada a cada uno de los dos tipos de clasificación

Metodología

Entrenamiento

Parámetros ajustados:

1. Número de épocas: 3 épocas
2. Tamaño de lote: 16
3. Tasa de aprendizaje: $2 \cdot 10^{-5}$

Parámetros contabilizados:

1. Pérdida en la validación
2. Tiempo invertido en el entrenamiento

Metodología



Evaluación

Métricas utilizadas:

1. Accuracy
2. Precision
3. Recall
4. F1-score
5. Matriz de confusión

Resultados

Clasificación Multiclase




	precision	recall	f1-score
pants-fire	0.00	0.00	0.00
false	0.26	0.35	0.30
barely-true	0.24	0.08	0.12
half-true	0.23	0.29	0.26
mostly-true	0.26	0.53	0.35
true	0.34	0.05	0.08


Resultados

Clasificación Binaria

Distribución real de noticias en el test set (C. Binaria)



Matriz de Confusión - Clasificación Binaria



	precision	recall	f1-score
False	0.71	0.80	0.75
True	0.53	0.41	0.46

Conclusiones

- Clasificación multiclase:
 - Más cercana a la realidad
 - Mal rendimiento: desequilibrio de clases
- Clasificación binaria:
 - Mejor rendimiento, pero sigue habiendo desbalanceo.
 - Mejor clasificación de noticias falsas que verdaderas.

Mejoras a futuro

- Balancear las clases del dataset
- Técnicas de ***data augmentation***
- Modelos más avanzados: RoBERTa