



DETECCIÓN DE NOTICIAS FALSAS MEDIANTE
MODELOS DE LENGUAJE PREENTRENADOS
Sistemas de Recuperación de Información y de
Recomendación

Máster en Ciencia de Datos e Ingeniería de
Computadores

Ana Fuentes Rodríguez

Curso 2024/25

Índice

1. Objetivos	2
2. Introducción	2
3. Fundamento teórico	2
4. Metodología	3
4.1. Descripción del dataset utilizado	3
4.2. Preprocesamiento de los datos	3
4.3. Arquitectura del modelo	4
4.4. Entrenamiento	4
4.5. Evaluación	4
5. Resultados	5
5.1. Modelo de clasificación multiclase	5
5.2. Modelo de clasificación binaria	7
6. Conclusiones	9
Referencias	10

Resumen

En este proyecto, se ha estudiado la detección automática de noticias falsas (*fake news*) mediante la implementación de dos modelos de clasificación utilizando *BERT base uncased*. Por un lado, se ha realizado un modelo capaz de clasificar el dataset en seis clases diferentes, según el grado de falsedad de la afirmación, siendo este un problema multiclase. Por otro lado, para simplificar este problema (aunque no es tan realista), se ha generado un modelo que clasifica el dataset en dos clases (verdadero o falso), reagrupando para ello las etiquetas de los datos en dos únicas categorías. En ambos casos, ha sido crucial el preprocesamiento de los datos (todo el texto en minúscula, eliminación de *stopwords*, espacios y otros caracteres, etc.). Tras todo esto, se ha entrenado y validado ambos modelos y, finalmente, se han evaluado y se han graficado las distribuciones de los datos según las categorías. Además, para el test set se han generado las matrices de confusión y las métricas *accuracy*, *precision*, *recall* y *F1-score* para analizar el buen o mal funcionamiento de estos dos modelos, comparándolos también entre sí (también se han mostrado las pérdidas y el tiempo invertido en el test).

1. Objetivos

El objetivo principal de este trabajo es desarrollar un sistema capaz de detectar automáticamente noticias falsas, basándose para ello en procesamiento de lenguaje natural y modelos de lenguaje profundo. Para alcanzar este objetivo, se realiza un preprocesamiento de los datos específico para textos y lenguaje natural, evaluando después su rendimiento en tareas de clasificación multiclase, por un lado, y binaria, por otro, sobre el dataset *LIAR*.

2. Introducción

En la actualidad, la gran cantidad de información de la que se dispone es abismal, además de la facilidad con la que se puede acceder a ella y adquirir conocimiento de prácticamente cualquier tema y de manera inmediata. A pesar de las considerables y evidentes ventajas que conlleva tener esta gran cantidad de información al alcance de la mano, esto también causa la rápida propagación de las conocidas *fake news* (en español, noticias falsas). Estas noticias engañosas pueden influir negativamente en la opinión pública, afectar procesos democráticos, y generar desinformación a gran escala. Por lo tanto, la detección automática de estas noticias falsas es un reto relevante y actual para preservar la integridad informativa en internet [1], [2].

Debido a los últimos avances en el procesamiento del lenguaje natural o NLP (por sus siglas en inglés, *Natural Language Processing*) y los modelos creados de lenguaje profundo, es posible afrontar el problema de detección de noticias falsas de forma más eficiente que en comparación con los métodos tradicionales. Además, dentro del contexto de los sistemas de recuperación de información, la existencia de estos modelos pueden clasificar documentos de texto según su veracidad, consiguiendo de este modo una mejora en la calidad de la información de la que se dispone en internet.

De este modo, se han realizado dos modelos basados en lenguaje profundo capaces de clasificar diferentes afirmaciones de naturaleza política. Primero, se ha generado un clasificador multiclase, eligiendo entre seis categorías. Después, se ha realizado otro clasificador binario, que clasifica las mismas noticias, pero en esta ocasión entre dos únicas clases; verdadero y falso. Estos dos modelos se han comparado utilizando diferentes métricas, como la precisión o la matriz de confusión, entre otras.

Así pues, este documento se distribuye de la siguiente forma: primero, se desarrolla un breve marco teórico con los conceptos clave relacionados con el procesamiento del lenguaje natural. En segundo lugar, se muestra la metodología que se ha seguido durante la experimentación, mostrando posteriormente el análisis de los resultados obtenidos y terminando con las conclusiones que se pueden extraer de estos.

3. Fundamento teórico

La detección automática de noticias engañosas resulta una tarea de clasificación de texto muy interesante, que forma parte del procesamiento de lenguaje natural. El objetivo esencial de esta rama de la inteligencia artificial es permitir la comprensión, interpretabilidad y generación de lenguaje humano por las máquinas.

Esta actividad trata de asignar una categoría a una sentencia de texto, como puede ser “verdadero” o “falso”, según el contenido semántico que tenga la oración [3].

Uno de los avances de los últimos años dentro del campo del procesamiento de lenguaje natural ha resultado ser la introducción de modelos de lenguaje profundo pre-entrenados, como ocurre con el modelo BERT (*Bidirectional Encoder Representations from Transformers*) [4]. En concreto, este modelo ha representado un cambio de paradigma en la forma en que se representan las oraciones; lo que se debe a que este modelo es bidireccional. A diferencia de otros, BERT tiene en cuenta tanto el contexto anterior como posterior a cada palabra, generando mejores representaciones contextuales.

De esta manera, el modelo BERT ha obtenido un rendimiento superior a otros modelos en tareas como clasificación de texto, análisis de sentimientos y preguntas y respuestas. En este trabajo en concreto, se ha empleado el modelo *BERT base uncased*, que ha sido pre-entrenado sobre grandes conjuntos en inglés y ajustado específicamente para la tarea de detección de noticias falsas utilizando el dataset LIAR, un dataset introducido por Wang [5] y contiene más de 12000 afirmaciones sobre política etiquetadas en función de su veracidad (seis niveles posibles), convirtiéndose en un referente en la investigación sobre noticias falsas.

Modelos como el que se ha utilizado en este trabajo tienen la particularidad de poder abordar el problema desde una perspectiva semántica profunda. El significado de las afirmaciones se representa de forma contextual y distribuida, y no se reduce a palabras clave o patrones. Esta característica lo hace muy poderoso a la hora de detectar noticias engañosas, las que pueden contener lenguaje ambiguo, irónico e incluso deliberadamente malintencionado.

4. Metodología

A continuación, se han descrito los pasos que se han debido de seguir para desarrollar de manera adecuada los modelos de detección automática de noticias falsas aplicando lenguaje profundo. De esta manera, se han llevado a cabo los siguientes cinco pasos bien marcados: elección del conjunto de datos, preprocesamiento y limpieza del mismo, implementación de los modelos de clasificación (multiclase y binaria), entrenamiento de los modelos y, por último, evaluación de estos.

4.1. Descripción del dataset utilizado

Para comenzar este proyecto, se ha seleccionado el conjunto de datos *LIAR dataset* [6], un dataset ampliamente utilizado para la clasificación de noticias según su grado de veracidad. En concreto, este dataset contiene 12836 instancias en total, siendo estas breves afirmaciones políticas, extraídas de fuentes como *PolitiFact.com*, acompañadas por su correspondiente etiqueta que les otorga un grado de veracidad o falsedad; *pants-fire, false, barely-true, half-true, mostly-true* y *true*. Además, este dataset contiene información sobre el tema de la declaración, el autor de cada afirmación y su afiliación política. De este modo, se han utilizado las seis clases en las que se organizan las instancias para el primer modelo, pero para el modelo de clasificación binaria se han simplificado en dos únicas clases, reorganizando las etiquetas a “verdadero” (1) o “falso” (0).

Por último, este conjunto se divide en otros tres subconjuntos: en primer lugar, para entrenar los modelos (10256 instancias), seguidamente, para validarlos (1284 ejemplos) y, finalmente, para evaluarlos (1267 ejemplos).

4.2. Preprocesamiento de los datos

Previo a la implementación del código para la detección de noticias falsas, es indispensable realizar un preprocesamiento adecuado de las afirmaciones. En primer lugar, se ha llevado a cabo una limpieza básica del texto: se transformaron todas las letras a minúsculas, se han eliminado caracteres especiales, espacios redundantes y URLs. También sería necesario eliminar las *stopwords* (palabras sin significado en las noticias; “el”, “un”, etc.), pero con el método que se ha utilizado no es necesario puesto que ya se ocupa de eso. Posteriormente, se han explorado dos esquemas de clasificación:

1. Clasificación multiclase: en este caso, se han mantenido las seis categorías originales del dataset a las que pertenece cada noticia política.

2. Clasificación binaria: por el contrario, en este caso se han agrupado las seis etiquetas en dos únicas clases: falso (agrupando *pants-fire*, *false*, *barely-true*, *half-true*) y verdadero (agrupando *mostly-true* y *true*).

Realizar la comparación entre ambas situaciones permite realizar un análisis acerca del impacto que se produce sobre el rendimiento del modelo al realizar la simplificación. Es importante también tener en cuenta que, a la hora de reagrupar los datos en etiquetas binarias, hay muchas más instancias etiquetadas como falsas en comparación con las verdaderas, por lo que se puede esperar un problema con el desbalanceo de clases.

4.3. Arquitectura del modelo

Una vez están todos los datos preprocesados y listos para trabajar con ellos, se ha procedido a implementar ambos clasificadores. El modelo utilizado para los dos enfoques ha sido *BERT base uncased*, un modelo de lenguaje pre-entrenado desarrollado por Google [4], el cual es un modelo ampliamente utilizado en problemas de clasificación de texto. Además, se ha utilizado la implementación de *Hugging Face Transformers* [7], que permite ajustar fácilmente el modelo para tareas de clasificación. Como se ha mencionado anteriormente, este es capaz de detectar y eliminar las palabras que no aportan información al clasificador sobre la veracidad de la afirmación, consiguiendo de esta manera que la detección sea más eficiente y el rendimiento sea mayor. Por último, se ha modificado la capa de salida del modelo en función del número de clases: seis categorías para el enfoque multiclase y dos para el binario.

4.4. Entrenamiento

A continuación, se han ajustado diferentes parámetros para realizar el ajuste fino del modelo BERT (o *fine-tuning*):

1. Número de épocas (*epochs*): 3 épocas. Añadir más épocas puede mejorar los resultados, aunque disminuye mucho la eficiencia, aumentando el tiempo de entrenamiento y puede incluso causar un sobreajuste.
2. Tamaño de lote (*batch size*): 16. Si se aumenta el tamaño puede dar estimaciones mejores del gradiente, pero puede sobreajustarse y necesita más memoria. Por el contrario, si se reduce este valor, generaliza mejor pero el entrenamiento se vuelve más inestable.
3. Tasa de aprendizaje (*learning rate*): $2 \cdot 10^{-5}$. Si se aumenta este valor, puede converger más rápido, pero se vuelve más inestable. Por otro lado, si se disminuye se vuelve más estable pero puede quedar atrapado en mínimos locales y obtenerse un resultado peor.

Por último, durante el entrenamiento del modelo se ha monitorizado la pérdida de la validación y, finalmente, se ha elegido el que mejor rendimiento aporta. También se ha contabilizado el tiempo que invierte en el entrenamiento.

4.5. Evaluación

Para finalizar, tras entrenar el modelo se ha evaluado el rendimiento de dicho modelo sobre el conjunto de test. Las métricas utilizadas para ello han sido:

- *Accuracy*: es el porcentaje de predicciones realizadas correctamente.
- *Precision*: esta métrica indica qué proporción de los ejemplos clasificados como positivos son, efectivamente, positivos.
- *Recall*: esta métrica, a diferencia de la anterior, indica qué proporción de los positivos reales ha sido bien identificada.
- *F1-score*: esta es la media armónica entre la precisión y la exhaustividad. Esta métrica es muy útil en problemas como el que se está tratando donde hay clases desbalanceadas.
- Matriz de confusión: esta sirve para entender visualmente el comportamiento del modelo en cada clase.

Además, se han generado gráficos para analizar la distribución de clases y comparar los resultados entre los modelos multiclase y binario.

5. Resultados

5.1. Modelo de clasificación multiclase

En primer lugar, se ha implementado el modelo de clasificación con la capa final preparada para clasificar las noticias en seis categorías. Tras entrenar y validar este modelo con los datasets convenientes, se ha evaluado y se han obtenido los resultados de la Tabla 1 y la Tabla 2 para las métricas de evaluación y otras estadísticas. Por otro lado, en la Figura 1 se ha representado la distribución que siguen los datos dentro del conjunto de prueba, con el fin de analizar las consecuencias de no existir un equilibrio entre las diferentes clases. En la Figura 2, por otra parte, se ha mostrado la matriz de confusión resultante de la evaluación.




Figura 1: Distribución original de los datos según las seis clases en el conjunto de prueba.




Figura 2: Matriz de confusión de las diferentes clases para el modelo de clasificación multiclase.

	precision	recall	f1-score
pants-fire	0.00	0.00	0.00
false	0.26	0.35	0.30
barely-true	0.24	0.08	0.12
half-true	0.23	0.29	0.26
mostly-true	0.26	0.53	0.35
true	0.34	0.05	0.08
accuracy			0.25
macro avg	0.22	0.22	0.18
weighted avg	0.25	0.25	0.21

Tabla 1: Resultados de las métricas tras la evaluación del modelo de clasificación multiclase.

Loss eval	Accuracy eval	F1 eval	Runtime eval
1.67	0.252	0.212	3.64

Tabla 2: Otras estadísticas obtenidas tras la evaluación del modelo de clasificación multiclase con el conjunto de datos de prueba.

Tras evaluar este modelo y analizar tanto la matriz de confusión como las métricas resultantes, se puede comprobar cómo estos resultados son nefastos. El clasificador apenas es capaz de detectar correctamente los datos en las categorías correspondientes. En concreto, para la clase *pants-fire* este clasificador no ha conseguido clasificar correctamente ninguna afirmación perteneciente a esta categoría. Esto puede deberse a que, para esta clase, existen muy pocos ejemplos (dataset desbalanceado), por lo que se produce un sesgo e impide que el modelo clasifique estas noticias correctamente.

Por otro lado, la clase *true* ha obtenido la mayor precisión (sobre el 34 %), aunque el recall obtenido ha sido del 0.08 %. Este suceso indica que, cuando el clasificador dice que la noticia es verdadera, hay un mayor grado de probabilidad de que lo sea, por lo que minimiza los falsos positivos. Sin embargo, al tener un valor de recall tan ínfimo, hay un gran número de falsos negativos. Esto también ocurre con la clase *barely-true*. En las otras clases ocurre lo contrario, aunque no es una diferencia tan exagerada.

En general, el resultado final del *accuracy* es realmente bajo (alrededor del 25 %) y tiene una pérdida de 1.67, por lo que este modelo no sirve para prácticamente nada, puesto que tiene un rendimiento muy bajo. A pesar de esto, es un modelo eficiente, pues el tiempo que invierte en evaluarse es breve, aunque a la hora de entrenarlo se invierte un poco más (cerca de cinco minutos), podría perderse eficiencia a cambio de mejorar estos resultados, aumentando el número de datos, haciendo técnicas para mejorar el balanceo entre clases (*oversampling*, *undersampling*, ...).

5.2. Modelo de clasificación binaria

En segundo lugar, se ha implementado el modelo de clasificación binaria, el cual, debido a la mayor simplicidad del problema, tendría que arrojar mejores resultados. Así pues, aplicando el mismo preprocesamiento que para el modelo anterior, se han obtenido los resultados para las diferentes métricas mostrados en la Tabla 3, además de la pérdida en la evaluación y el tiempo en la Tabla 4. En la Figura 3 se ha mostrado la distribución que siguen los datos en las clases en el conjunto de datos y en la Figura 4 se ha reflejado la matriz de confusión obtenida tras la evaluación de este modelo.




Figura 3: Distribución real de los datos de prueba clasificados en cada una de las dos clases (verdadero: 1 o falso: 0).




Figura 4: Matriz de confusión resultante para la evaluación del modelo de clasificación binaria.

	precision	recall	f1-score
False	0.71	0.80	0.75
True	0.53	0.41	0.46
accuracy			0.66
macro avg	0.62	0.60	0.61
weighted avg	0.65	0.66	0.65

Tabla 3: Resultado de las métricas arrojadas por el modelo al ser evaluado con el conjunto de test (datos etiquetados como verdaderos o falsos).

Loss eval	Accuracy eval	F1 eval	Runtime eval
0.610	0.662	0.650	3.50

Tabla 4: Otras estadísticas obtenidas tras la evaluación del modelo de clasificación binaria con el conjunto de datos de prueba.

Como se puede comprobar en estas métricas y en la matriz de confusión, este modelo mejora considerablemente los resultados de la clasificación en comparación con el modelo anterior. En efecto, como ahora

el problema más sencillo, al clasificador le ha resultado más fácil identificar las diferencias entre las afirmaciones falsas y las verdaderas. Sin embargo, el clasificador detecta considerablemente peor las noticias catalogadas como verdaderas, lo que posiblemente es debido al desbalanceo presente en el conjunto (hay la mitad de datos clasificados como verdaderos que como falsos).

A pesar de esto, clasifica medianamente bien las noticias falsas, presentando una precisión del 71 % y un recall del 80 %. Al tener un mayor recall, hay un menor número de falsos negativos, por lo que este clasificador es bueno si se prefiere detectar el mayor número de noticias falsas posibles, aunque puede ocurrir que el clasificador identifique noticias verdaderas como falsas. Por ejemplo, a la hora de detectar noticias falsas en medios sociales, donde prima la eliminación de estas noticias, aunque haya afirmaciones ciertas detectadas como falsas.

Este clasificador resuelve un problema más irreal que el anterior (en la vida real, muchas afirmaciones no son completamente ciertas o completamente falsas). No obstante, la pérdida en la evaluación es notablemente inferior a la anterior, mejorando el accuracy y el F1-score generales, manteniendo el tiempo invertido en el entrenamiento y en el test más o menos constantes.

6. Conclusiones

Para este proyecto, se ha desarrollado un sistema capaz de detectar de manera automática afirmaciones políticas falsas, utilizando técnicas de procesamiento de lenguaje natural y modelos de lenguaje profundo. Entonces, se han abordado dos enfoques: Por un lado, una clasificación multiclase (más realista pero más complejo) y, por otro, una clasificación binaria (más simple pero más alejado de la realidad).

Tras la realización de este trabajo, se ha podido concluir que, en efecto, la detección de noticias falsas es un problema muy complejo de resolver, teniendo en cuenta diferentes aspectos. Por un lado, el primer modelo generado (clasificador multiclase) es un modelo más realista, puesto que considera diferentes grados de falsedad (no todo es totalmente cierto o completamente falso). Sin embargo, este modelo arroja resultados realmente malos, siendo incapaz de clasificar correctamente las noticias con categorías más extremas, posiblemente influenciado por un desequilibrio entre las diferentes clases.

Por otro lado, se ha realizado un segundo modelo de clasificación, pero en esta ocasión se ha simplificado el problema a una clasificación binaria. De este modo, la complejidad se reduce notablemente, como es evidente. Aunque no son resultados excelentes, este clasificador es capaz de distinguir mejor las noticias categorizadas como falsas de las verdaderas. Aun así, existe un desbalanceo entre clases, lo que conlleva un desequilibrio en las métricas, puesto que clasifica mejor las falsas de las verdaderas, lo que tampoco es favorable (no es conveniente clasificar las noticias verdaderas como falsas, puesto que puede llevar a confusiones).

En definitiva, este problema necesita una gran investigación para poder mejorar estos modelos y poder identificar mejor las noticias falsas frente a las verdaderas. Esto podría mejorar añadiendo más datos mediante técnicas de *data augmentation* y controlando que haya un buen balance entre todas las clases. Otra posible mejora es implementar diferentes modelos, como el mmodelo *RoBERTa*.

Referencias

- [1] X. Zhou and R. Zafarani, “Fake news: A survey of research, detection methods, and opportunities,” *arXiv preprint arXiv:1812.00315*, vol. 2, p. 13, 2018.
- [2] K. Shu, A. Sliva, S. Wang, J. Tang, and H. Liu, “Fake news detection on social media: A data mining perspective,” *ACM SIGKDD explorations newsletter*, vol. 19, no. 1, pp. 22–36, 2017.
- [3] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Prentice Hall, 3rd ed., 2021. Draft version available online.
- [4] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pp. 4171–4186, 2019.
- [5] W. Y. Wang, ““liar, liar pants on fire”: A new benchmark dataset for fake news detection,” *arXiv preprint arXiv:1705.00648*, 2017.
- [6] Q. Doan, “Liar-dataset,” 2022. Dataset disponible en Kaggle.
- [7] H. Face, “Hugging face documentation,” n.d.